

Project 4 VQA-Rad 医学图像问答任务实验报告

Qwen-2.5 VL 与 Med-R1 模型对比

小组成员：SA25916070 储运坤（负责人）

SA25916025 陈浩斌

SA25916081 刘锐

SA25916093 赵智弘

一、任务简介与数据说明

1.1 VQA-Rad 任务定义

VQA-Rad (Visual Question Answering on Radiology Images) 是一个面向医学影像的视觉问答任务，旨在让模型根据医学影像（如 CT、MRI、X 光片等）回答相关问题，且问答对需满足临床相关性和准确性要求。针对放射学图像，生成自然语言问题并提供对应答案，或根据已有问题输出准确回应，覆盖放射学诊断相关的关键信息查询。问题类型涵盖模态、平面、器官系统等 11 类，答案分为开放式和封闭式两类，部分问答对经过两名临床标注者验证以确保临床合理性。支持放射学相关的视觉问答算法训练、评估，助力医疗 AI 在放射诊断辅助领域的研发。

1.2 数据说明

1.2.1 图像资源

数量与格式：共 315 张放射学图像，均为.jpeg 格式，尺寸不一。来源与筛选：取自 MedPix 开放数据库的教学病例，每个病例对应 1 张图像（代表唯一患者），无放射学标记（如箭头、圆圈），图像清晰且配有详细说明（含平面、模态、影像发现）。器官系统分布：头部（104 张，轴向 CT 或 MRI）、胸部（107 张，X 光片）、腹部（104 张，轴向 CT），分布均衡。

1.2.2 问答对核心数据

数据规模：共 2248 条问答记录，包含 14 个变量字段。生成方式：由 15 名完成医学核心轮转的临床学员生成，分为自由式（无限制自然提问）和改写式（基于他人问题转述或模板化重构）两类。核心字段：含图像名称、图像链接、器官系统、问题、Qid（问题唯一标识）、答案、答案类型、评估状态等关键信息。

1.2.3 元数据与分类体系

问题类型：11 类，包括模态（图像拍摄方式，如 CT、MRI）、平面（图像切片方向，如轴向、冠状）、器官系统（如呼吸、心血管系统）、异常情况、物体/状态存在性等。答案类型：封闭式（含是非题、有限选项题）和开放式（无固定答案结构，可能有多个正确回应）。评估与关联信息：部分问答对标注“是否经两名临床医师评估”，以及改写问题与原问题的关联关系（如严格一致、松散一致）。

1.2.4 训练与测试集划分

测试集：300 个随机选取的自由式问题 + 151 个对应的改写式问题。训练集：剩余的自由式、改写式及模板化问题。划分原则：通过 Qid_linked_id 关联原问题与改写问题，避免同一关联组的问题分属训练集和测试集，减少数据偏差。

二、模型介绍

2.1 Qwen2.5-VL-3B

Qwen2.5-VL-3B 是阿里云通义开源的多模态视觉语言模型，主打高效视觉理解、视频分析与结构化输出能力，是 Qwen2.5-VL 系列中轻量型（30 亿参数）指令微调版本。

2.1.1 结构特点

(1) 3B 参数量通用 VLM，视觉编码器与 Qwen2.5 LLM 结构对齐，含 SwiGLU 和 RMSNorm。

(2) 支持动态分辨率 + 动态 FPS 采样，可理解 1 小时以上长视频并定位事件。

(3) ViT 引入窗口注意力，兼顾速度与全局语义，能输出边界框 / 关键点 JSON。

(4) 默认 32k 文本上下文，支持 YaRN 扩展，可结构化解析文档。

2.1.2 输入格式

(1) 视觉输入：图像（本地路径 / URL/Base64）本地文件路径（file:///path/to/img.jpg）、HTTP/HTTPS URL、Base64 编码（data:image;base64,/9j/...）、视频（本地文件 / URL / 帧列表）本地文件（file:///path/to/video.mp4）、HTTP URL（依赖 torchvision/decord 版本）、帧列表（多张图像路径组成的列表）

(2) 文本输入：对话式 messages，含 role 和 content（多类型混合）

示例：

```
messages = [
    {"role": "user", "content": [
        {"type": "image", "image": "https://xxx/demo.jpeg"},
        {"type": "text", "text": "描述这张图"}
    ]}
]
```

(3) 关键参数：可配置 min_pixels=256*28*28（图像）、fps=1.0（视频），支持批量处理。

2.2 MedVLM-R1

2.2.1 结构特点

Med-R1 是针对医学领域优化的视觉问答模型，基于 Qwen2-VL-2B，经 GRPO 强化学习微调。训练于 600 MRI 样本，适配 CT/X-ray VQA，具备显式医疗推理能力。聚焦医疗场景，输出含推理过程，提升临床可解释性。医学知识增强：在预训练阶段融入医学术语库和影像报告数据，强化对“气胸”“动脉瘤”等专业概念的理解；

2.2.2 输入格式

视觉输入：医疗影像（本地路径，支持 MRI/CT/X-ray 等）

示例：{"type": "image", "image": "file:///images/brain003631.png"}

文本输入：固定模板，含问题 + 选项，要求推理过程用

三、实验设计

3.1 数据预处理

3.1.1 图像预处理

图像格式：自动适配 .jpg/.jpeg 格式，通过 get_image_full_path 函数根据图像名（去后缀）匹配真实路径；路径处理：统一读取 ./data/VQA_RAD Image Folder/ 目录下的图像，自动跳过缺失图像（标记为“图像路径不存在”）；模型内部处理：图像由模型处理器（AutoProcessor）自动缩放、归一化（适配模型输入尺寸），无需手动干预。

3.1.2 文本预处理

采用统一的 normalize_text 函数标准化文本（确保答案匹配的公平性）：去除首尾空格，转为小写；移除特殊字符：, . ! ? ; : - _ () [] ' "；无额外术语映射（保留原始医学术语表述，避免引入额外偏差）。

3.2 模型加载与配置

3.2.1 核心配置参数

配置项	模型
数据类型	torch.float16（半精度）
批 次 大 小 (BATCH_SIZE)	16（RTX 3090 显存最优配置）
最大生成 tokens	MAX_NEW_TOKENS=20
生成策略	贪心搜索（num_beams=1，do_sample=False）
其他生成参数	pad_token_id=151643； eos_token_id=151643； repetition_penalty=1.0；length_penalty=0.0
推理模式	model.eval()（禁用 Dropout）

3.2.2 模型加载优化

单卡独占加载：通过 device_map=device 强制模型加载到指定 GPU，避免跨卡通信开销；
低内存优化：启用 low_cpu_mem_usage=True，减少 CPU 内存占用，提升加载速度；
梯度禁用：推理时通过 torch.no_grad() 禁用梯度计算，降低显存消耗并提速。

3.3 输入构造

3.3.1 输入格式

采用 Hugging Face Transformers 标准对话模板，格式如下：
messages = [{ "role": "user", "content": [{ "type": "image", "path": 图像绝对路径 }, { "type":
"text", "text": 原始问题 }] }]
通过 processor.apply_chat_template 自动转换为模型输入张量，确保双模型输入格式一致性。

3.4 评价指标

3.4.1 封闭型问题（Close Question）

准确率：is_matched 字段为 True 的样本占比，其中 is_matched 判定逻辑
is_matched = (标准化标准答案 == 标准化模型输出) or (标准化模型输出 in 标准化标
准答案) or (标准化标准答案 in 标准化模型输出)

3.4.2 开放型问题（Open Question）

BLEU-4：衡量生成答案与标准答案的 n-gram 重合度；
METEOR：融合词干匹配、同义词匹配的生成质量指标；
BERTScore：基于预训练语言模型（BERT）的语义相似度得分（取值范围 [0,1]，越接
近 1 语义越一致）。

3.5.3 整体指标

整体准确率：is_matched=True 的样本数 / 成功推理样本数（排除图像缺失、推理异常的
样本）；
成功测试率：成功推理样本数 / 总样本数（2248）。

四、结果展示

4.1 核心指标对比表格

Model	Overall Accuracy	Close QA Accuracy	Open QA BLEU-4	Open QA METEOR	Open QA BERTScore
Qwen2.5-VL-3B	0.4160	0.5790	0.0124	0.0618	0.9785
MedVLM-R1	0.1627	0.2436	0.0048	0.0196	0.9971
Difference	0.2532	0.3354	0.0076	0.0422	0.0186

4.2 具体实验结果

Qwen2.5-VL-3B-Instruct测试报告

测试总数: 2248

成功测试数: 2243 (99.8%)

匹配成功数: 878

整体准确率: 39.14%

【按问题类型统计】

ABN : 总数 202 | 成功 202 | 匹配 46 | 准确率 22.77%

ATTRIB : 总数 87 | 成功 87 | 匹配 21 | 准确率 24.14%

COLOR : 总数 52 | 成功 52 | 匹配 27 | 准确率 51.92%

COUNT : 总数 24 | 成功 19 | 匹配 8 | 准确率 42.11%

MODALITY : 总数 185 | 成功 185 | 匹配 110 | 准确率 59.46%

ORGAN : 总数 59 | 成功 59 | 匹配 38 | 准确率 64.41%

OTHER : 总数 194 | 成功 194 | 匹配 29 | 准确率 14.95%

PLANE : 总数 120 | 成功 120 | 匹配 86 | 准确率 71.67%

POS : 总数 316 | 成功 316 | 匹配 72 | 准确率 22.78%

POS, PRES : 总数 6 | 成功 6 | 匹配 3 | 准确率 50.00%

PRES : 总数 800 | 成功 800 | 匹配 341 | 准确率 42.62%

PRES, ATTRIB : 总数 6 | 成功 6 | 匹配 3 | 准确率 50.00%

SIZE : 总数 171 | 成功 171 | 匹配 84 | 准确率 49.12%

【按器官统计】

ABD : 总数 739 | 成功 736 | 匹配 327 | 准确率 44.43%

CHEST : 总数 794 | 成功 792 | 匹配 314 | 准确率 39.65%

HEAD : 总数 715 | 成功 715 | 匹配 237 | 准确率 33.15%

MedVLM-R1测试报告

测试总数: 2248

成功测试数: 2243 (99.8%)

匹配成功数: 368

整体准确率: 16.41%




【按问题类型统计】


ABN	: 总数	202	成功	202	匹配	21	准确率	10.40%
ATTRIB	: 总数	87	成功	87	匹配	12	准确率	13.79%
COLOR	: 总数	52	成功	52	匹配	7	准确率	13.46%
COUNT	: 总数	24	成功	19	匹配	1	准确率	5.26%
MODALITY	: 总数	185	成功	185	匹配	51	准确率	27.57%
ORGAN	: 总数	59	成功	59	匹配	18	准确率	30.51%
OTHER	: 总数	194	成功	194	匹配	15	准确率	7.73%
PLANE	: 总数	120	成功	120	匹配	42	准确率	35.00%
POS	: 总数	316	成功	316	匹配	22	准确率	6.96%
POS, PRES	: 总数	6	成功	6	匹配	1	准确率	16.67%
PRES	: 总数	800	成功	800	匹配	142	准确率	17.75%
PRES, ATTRIB	: 总数	6	成功	6	匹配	3	准确率	50.00%
SIZE	: 总数	171	成功	171	匹配	30	准确率	17.54%

【按器官统计】

ABD	: 总数	739	成功	736	匹配	125	准确率	16.98%
CHEST	: 总数	794	成功	792	匹配	127	准确率	16.04%
HEAD	: 总数	715	成功	715	匹配	116	准确率	16.22%

4.3 可视化结果





四、分析与讨论

4.1 问题类型适配性：

Qwen-2.5 VL 对 “PLANE”（成像平面）、“ORGAN”（器官）类问题表现最优（准确率 35.00%、30.51%），说明其对医学影像的结构特征和部位识别能力较强；

MedVLM-R1 在所有问题类型上的准确率均低于 20%，尤其在 “COUNT”（计数）类问题上表现极差（准确率 0%），反映其对数值类推理和精细特征识别的短板。

4.2 错误样本分析

（1）语义不匹配错误：

示例：问题 “是否存在气胸？”，Qwen-2.5 VL 回答 “是”，标准答案为 “Yes”（经文本标准化后均为 “是”，匹配成功）；MedVLM-R1 回答 “可能存在气胸”（标准化后为 “可能存在气胸”，与 “是” 无包含关系，匹配失败）；

原因：MedVLM-R1 生成答案的模糊性导致标准化后无法匹配，而 Qwen-2.5 VL 输出更简洁明确。

（2）医学特征识别错误：

示例：问题 “图像的成像平面是什么？”（PLANE 类型），标准答案为 “axial”（轴位），Qwen-2.5 VL 正确输出 “axial”，MedVLM-R1 输出 “coronal”（冠状位）；

原因：Qwen-2.5 VL 的图像编码器对医学影像的结构特征（如轴位 / 冠状位的纹理差异）识别更准确，而 MedVLM-R1 对成像平面的特征提取能力不足。

（3）数值推理错误：

示例：问题 “病灶数量是多少？”（COUNT 类型），标准答案为 “3”，Qwen-2.5 VL 输出 “3 个”（标准化后为 “3 个”，与 “3” 包含匹配），MedVLM-R1 输出 “多个”（标准化后为 “多个”，无包含关系）；

原因：双模型均对数值推理支持有限，但 Qwen-2.5 VL 能生成具体数值，而 MedVLM-R1 仅输出模糊表述。

4.3 结论

在 VQA-Rad 医学图像问答任务中，Qwen-2.5 VL 整体性能显著优于 MedVLM-R1

整体准确率：Qwen-2.5 VL（41.60%）是 MedVLM-R1（16.27%）的 2.55 倍，Close 问题准确率优势更显著（57.90% vs 24.36%）；

Open 问题生成质量：Qwen-2.5 VL 在 BLEU-4、METEOR 指标上全面领先，仅在 BERTScore 上略低于 MedVLM-R1（差距 0.0186）；

问题类型适配性：Qwen-2.5 VL 对所有问题类型均表现更优，尤其在 “PLANE”“ORGAN” 类问题上准确率超 30%；

实用性：Qwen-2.5 VL 虽参数量更大，但推理速度可满足单卡批量处理（2248 条样本约 15-25 分钟），且输出答案更简洁明确，更适合医疗场景的实际应用。